Documento técnico
Requerimientos de hardware

Plataforma Aiuda

Especificación técnica para despliegue en servidor propio

Este documento describe los requerimientos mínimos, recomendados y óptimos de hardware para desplegar la plataforma Aiuda en un servidor propio o máquina virtual (VM). Se incluyen estimaciones de almacenamiento, red y costos aproximados.

1. Requerimientos de hardware

Los modelos de inteligencia artificial que utiliza Aiuda (Whisper para transcripción y NLLB para traducción) requieren recursos suficientes para operar en memoria simultáneamente. A continuación se detallan tres niveles de configuración.

Componente	Mínimo	Recomendado	Óptimo (con GPU)
CPU	4 cores	16–24 cores	16+ cores + GPU NVIDIA
RAM	8 GB	12–16 GB	16–32 GB
GPU	No requerida	No requerida	NVIDIA CUDA, 4 GB VRAM mín.
Sistema operativo	Ubuntu 22.04+	Ubuntu 24.04	Ubuntu 24.04
Docker	Engine 24+ / Compose v2	Engine 24+ / Compose v2	Engine 24+ / Compose v2

- Con la configuración mínima (4 cores, 8 GB RAM), la plataforma funciona pero el procesamiento puede ser lento. Un video de 1 minuto puede tardar entre 2 y 4 minutos en procesarse.
- Con GPU NVIDIA compatible con CUDA, el tiempo de procesamiento se reduce entre 5 y 10 veces respecto al CPU.
- Los modelos Whisper y NLLB ocupan en conjunto aproximadamente 4–5 GB de RAM durante el procesamiento.

2. Almacenamiento

El almacenamiento se divide en dos partes: el espacio fijo para el sistema y los modelos de IA, y el espacio variable de la carpeta jobs/, que crece con cada tarea procesada.

	Tamaño estimado	Notas
Sistema operativo + Docker	~5 GB	Fijo, no varía
Modelos de IA (Whisper + NLLB)	~3 GB	Se descargan la primera vez
Imagen Docker backend	~7 GB	Fijo tras el primer build
jobs/ — video de 1h, 1 idioma	~500 MB	Original + MP4 subtitulado + SRT/JSON
jobs/ — video de 1h, 4 idiomas	~2–4 GB	Un MP4 subtitulado por idioma
jobs/ — audio de 1h	~100–200 MB	MP3 + archivos de texto/subtítulos
jobs/ — documento PDF	~5–20 MB	PDF + archivos traducidos

- La carpeta jobs/ crece indefinidamente si no se implementa una política de retención. Se recomienda eliminar tareas con más de 30 días de antigüedad.
- Almacenamiento total recomendado: 100–200 GB para uso moderado (hasta 50 videos de 1 hora con 4 idiomas).

3. Red

Aiuda procesa todos los archivos localmente una vez que los modelos están descargados. No envía datos a servidores externos durante el procesamiento.

Concepto	Detalle
Primera instalación	Descarga de modelos: ~3 GB. Requiere acceso a internet (Hugging Face y PyPI).
Procesamiento	100% offline. No se envían datos a servidores externos.
Subida de archivos	Un video de 1h puede pesar 1–4 GB. En red LAN 1 Gbps la transferencia es inmediata.

Proxy institucional	Si el servidor está detrás de un proxy, debe configurarse NO_PROXY para la comunicación interna entre contenedores Docker.

4. Costo estimado

Los costos a continuación son estimaciones de referencia en dólares estadounidenses para hardware de servidor. Si ya existe infraestructura disponible, el costo adicional puede ser nulo.

		Costo aprox. (USD)
Servidor físico (usado)	Dell/HP 2U, 24 cores, 64 GB RAM	$800–$2.000
Servidor físico (nuevo)	Tower workstation, 16 cores, 32 GB RAM	$2.500–$5.000
GPU (opcional)	NVIDIA RTX 3060/4060 (12 GB VRAM)	$300–$500
Almacenamiento SSD	500 GB NVMe para jobs/	$40–$80
Software	Linux + Docker + Aiuda	$0 (libre)
Total sin GPU	Servidor usado + SSD	~$850–$2.100
Total con GPU	Servidor + GPU + SSD	~$1.150–$2.600

- Si la institución ya cuenta con un servidor con capacidad disponible, el costo adicional se limita al almacenamiento (~$40–$80) y, opcionalmente, a una GPU.
- Los precios pueden variar según región y disponibilidad del mercado.

---

15 mayo 2026 / Fernando Valladares - Facultad de Ingeniería - UBA