Documento técnico
Requisitos de hardware

Plataforma Aiuda

Especificación técnica para a implementación in situ

Este documento describe os requisitos de hardware mínimos, recomendados e óptimos para implementar a plataforma Aiuda no seu propio servidor ou máquina virtual (VM). Inclúense almacenamento, rede e estimacións de custos aproximados.

1. Requerimientos de hardware

Os modelos de intelixencia artificial empregados por Aiuda (Whisper para a transcrición e NLLB para a tradución) requiren recursos suficientes para operar na memoria simultaneamente. A continuación detállanse tres niveis de configuración.

Compoñente	Mínimo	Recomendado	Óptimo (con GPU)
CPU	4 cores	16–24 cores	16+ cores + GPU NVIDIA
RAM	8 GB	12–16 GB	16–32 GB
GPU	No requerida	No requerida	NVIDIA CUDA, 4 GB VRAM mín.
Sistema operativo	Ubuntu 22.04+	Ubuntu 24.04	Ubuntu 24.04
Docker	Engine 24+ / Compose v2	Engine 24+ / Compose v2	Engine 24+ / Compose v2

- Coa configuración mínima (4 núcleos, 8 GB de RAM), a plataforma funciona, pero o procesamento pode ser lento. Un vídeo dun minuto pode tardar entre 2 e 4 minutos en procesarse.
- Cunha GPU NVIDIA compatible con CUDA, o tempo de procesamento redúcese de 5 a 10 veces en comparación coa CPU.
- Os modelos Whisper e NLLB xuntos usan aproximadamente de 4 a 5 GB de RAM durante o procesamento.

2. Almacenamento

O almacenamento divídese en dúas partes: o espazo fixo para o sistema e os modelos de IA, e o espazo variable dos traballos/cartafol, que medra con cada tarefa procesada.

	Tamaño estimado	Notas
Sistema operativo + Docker	~5 GB	Fixado, non varía
Modelos de IA (Whisper + NLLB)	~3 GB	Descargados a primeira vez
Imagen Docker backend	~7 GB	Corrixido despois da primeira compilación
jobs/ — video de 1h, 1 idioma	~500 MB	Orixinal+ MP4 subtitulado + SRT/JSON
jobs/ — video de 1h, 4 idiomas	~2–4 GB	Un MP4 subtitulado por idioma
jobs/ — audio de 1h	~100–200 MB	ficheiros de texto/subtítulos
jobs/ — documento PDF	~5–20 MB	PDF + ficheiros traducidos

- Os traballos/carpeta medra indefinidamente se non se implementa unha política de retención. Recoméndase eliminar tarefas de máis de 30 días.
- Almacenamento total recomendado: 100–200 GB para un uso moderado (ata 50 vídeos dunha hora en 4 idiomas).

3. Rede

Aiuda procesa todos os ficheiros localmente unha vez descargados os modelos. Non envía datos a servidores externos durante o procesamento.

Concepto	Detalle
Configuración inicial	Descarga do modelo: ~3 GB. Require acceso a internet (Hugging Face e PyPI).
Procesamento	100 % sen conexión. Non se envían datos a servidores externos.
Subida de ficheiros	Un vídeo dunha hora pode ter un tamaño de entre 1 e 4 GB. Nunha rede LAN de 1 Gbps, a transferencia é instantánea.
Proxy institucional	Se o servidor está detrás dun proxy, debe configurarse NO_PROXY para a comunicación interna entre os contedores de Docker.

4. Costo estimado

Os custos que se indican a continuación son estimacións de referencia en dólares estadounidenses para o hardware de servidor. Se xa existe unha infraestrutura, o custo adicional pode ser cero.

		Costo aprox. (USD)
Servidor físico (usado)	Dell/HP 2U, 24 cores, 64 GB RAM	$800–$2.000
Servidor físico (nuevo)	Tower workstation, 16 cores, 32 GB RAM	$2.500–$5.000
GPU (opcional)	NVIDIA RTX 3060/4060 (12 GB VRAM)	$300–$500
Almacenamento SSD	500 GB NVMe para jobs/	$40–$80
Software	Linux + Docker + Aiuda	$0 (libre)
Total sen GPU	Servidor usado + SSD	~$850–$2.100
Total con GPU	Servidor + GPU + SSD	~$1.150–$2.600

- Se a institución xa ten un servidor con capacidade dispoñible, o custo adicional limítase ao almacenamento (aproximadamente entre 40 e 80 dólares) e, opcionalmente, a unha GPU.
- Os prezos poden variar segundo a rexión e a dispoñibilidade no mercado.

---

15 mayo 2026 / Fernando Valladares – Facultad de Ingeniería – UBA