Documento técnico
Requisitos de hardware

Plataforma Aiuda

Especificações técnicas para implantação em um servidor doméstico

Este documento descreve os requisitos mínimos, recomendados e ideais de hardware para a implantação da plataforma Aiuda em um servidor doméstico ou máquina virtual (VM). Inclui informações sobre armazenamento, rede e estimativas de custos aproximados.

1. Requisitos de hardware

Os modelos de inteligência artificial usados pelo Aiuda (Whisper para transcrição e NLLB para tradução) exigem recursos suficientes para operar simultaneamente na memória. Três níveis de configuração são detalhados abaixo.

Componente	Mínimo	Recomendado	Óptimo (con GPU)
CPU	4 cores	16–24 cores	16+ cores + GPU NVIDIA
RAM	8 GB	12–16 GB	16–32 GB
GPU	Não é necessário	Não é necessário	NVIDIA CUDA, 4 GB VRAM mín.
Sistema operativo	Ubuntu 22.04+	Ubuntu 24.04	Ubuntu 24.04
Docker	Engine 24+ / Compose v2	Engine 24+ / Compose v2	Engine 24+ / Compose v2

- Com a configuração mínima (4 núcleos, 8 GB de RAM), a plataforma funciona, mas o processamento pode ser lento. Um vídeo de 1 minuto pode levar de 2 a 4 minutos para ser processado.
- Com uma GPU NVIDIA compatível com CUDA, o tempo de processamento é reduzido de 5 a 10 vezes em comparação com a CPU.
- Os modelos Whisper e NLLB juntos usam aproximadamente 4 a 5 GB de RAM durante o processamento.

2. Armazenamento

O armazenamento é dividido em duas partes: o espaço fixo para o sistema e os modelos de IA, e o espaço variável da pasta jobs/, que cresce a cada tarefa processada.

	Tamaño estimado	Notas
Sistema operacional + Docker	~5 GB	Fixo, não varia
Modelos de IA (Whisper + NLLB)	~3 GB	Baixado na primeira vez
Imagem do backend Docker	~7 GB	Fixo após a primeira compilação
jobs/ — vídeo de 1h, 1 idioma	~500 MB	Original + MP4 legendado + SRT/JSON
jobs/ — vídeo de 1h, 4 idiomas	~2–4 GB	Un MP4 legendado por idioma
jobs/ — audio de 1h	~100–200 MB	MP3 + arquivos de texto/legendas
jobs/ — documento PDF	~5–20 MB	PDF + arquivos traduzidos

- A pasta jobs/ cresce indefinidamente se uma política de retenção não for implementada. Recomenda-se excluir tarefas com mais de 30 dias.
- Armazenamento total recomendado: 100–200 GB para uso moderado (até 50 vídeos de uma hora em 4 idiomas).

3. Rede

Aiuda processa todos os arquivos localmente assim que os modelos são baixados. Ela não envia dados para servidores externos durante o processamento.

Concepto	Detalle
Configuração Inicial	Download do Modelo: ~3 GB. Requer acesso à internet (Hugging Face e PyPI).
Processamento	100% offline. Nenhum dado é enviado para servidores externos.
Upload de Arquivos	Um vídeo de 1 hora pode ter de 1 a 4 GB. Em uma LAN de 1 Gbps, a transferência é imediata.

Proxy institucional	Se o servidor estiver atrás de um proxy, a opção NO_PROXY deve ser configurada para comunicação interna entre contêineres Docker.

4. Custo estimado

Os custos abaixo são estimativas de referência em dólares americanos para hardware de servidor. Se a infraestrutura existente já estiver instalada, o custo adicional poderá ser zero.

		Costo aprox. (USD)
Servidor físico (usado)	Dell/HP 2U, 24 cores, 64 GB RAM	$800–$2.000
Servidor físico novo	Estação de trabalho torre, 16 cores, 32 GB RAM	$2.500–$5.000
GPU (opcional)	NVIDIA RTX 3060/4060 (12 GB VRAM)	$300–$500
Armazenamento SSD	500 GB NVMe para jobs/	$40–$80
Software	Linux + Docker + Aiuda	$0 (libre)
Total sem GPU	Servidor usado + SSD	~$850–$2.100
Total com GPU	Servidor + GPU + SSD	~$1.150–$2.600

- Se a instituição já possuir um servidor com capacidade disponível, o custo adicional se limita ao armazenamento (aproximadamente US$ 40 a US$ 80) e, opcionalmente, a uma GPU.
- Os preços podem variar dependendo da região e da disponibilidade no mercado.

---

15 de mayo 2026 / Fernando Valladares - Facultad de Ingeniería - UBA
20 de julio 2026 / Darío Riquelme Z. - EOL - VTI - UChile [Traducción usando google translate]